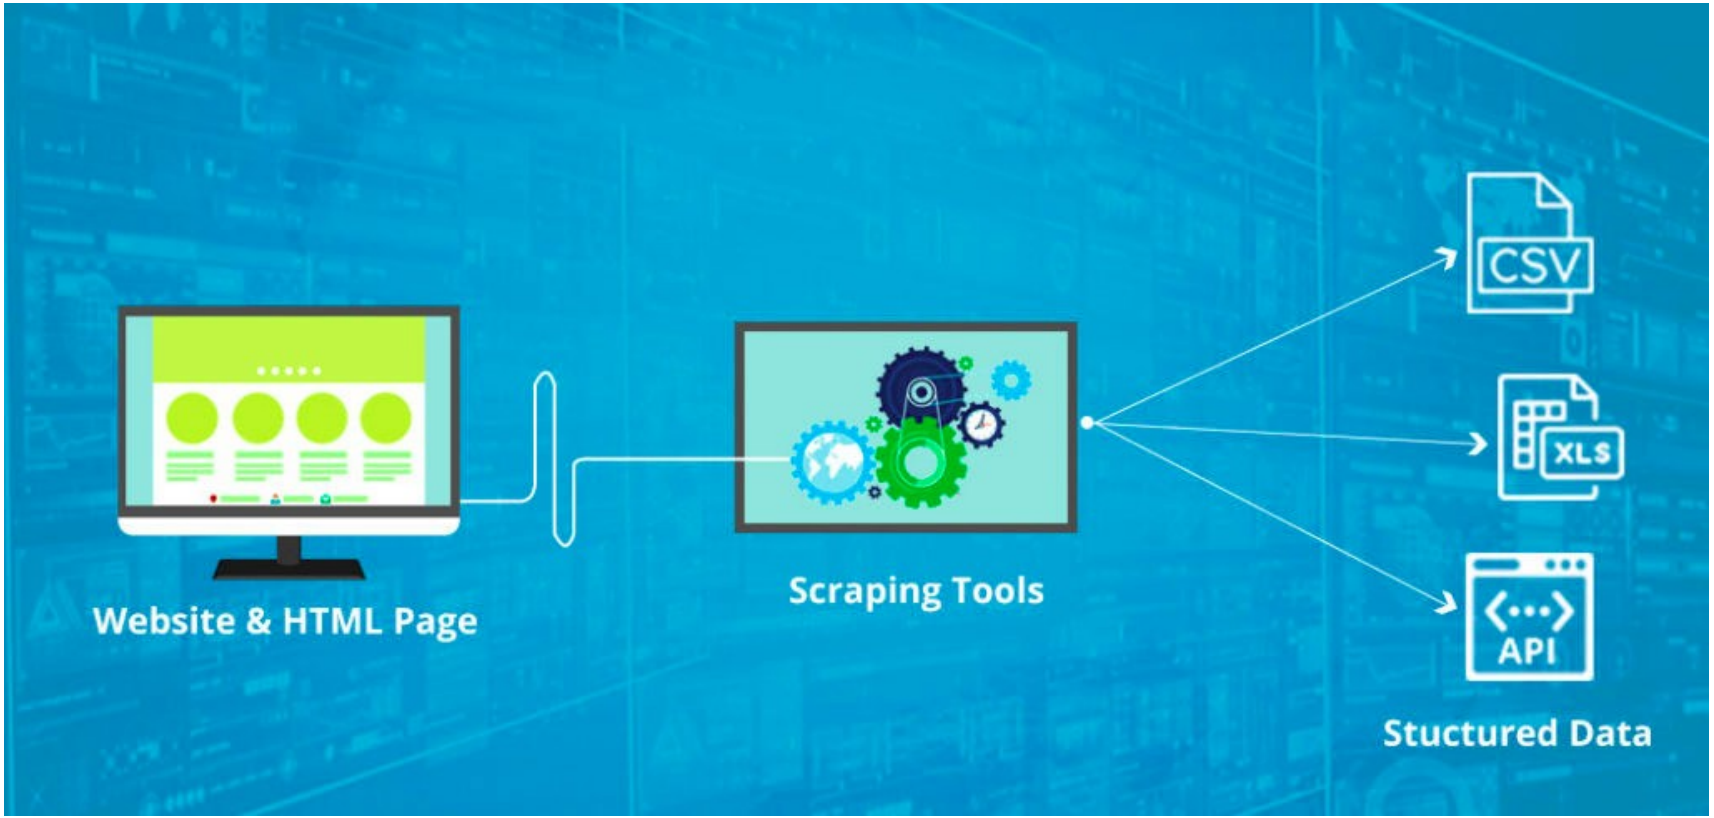
¿Porque usar python en ciencias sociales y humanas?



Páginas WEB y datos digitales



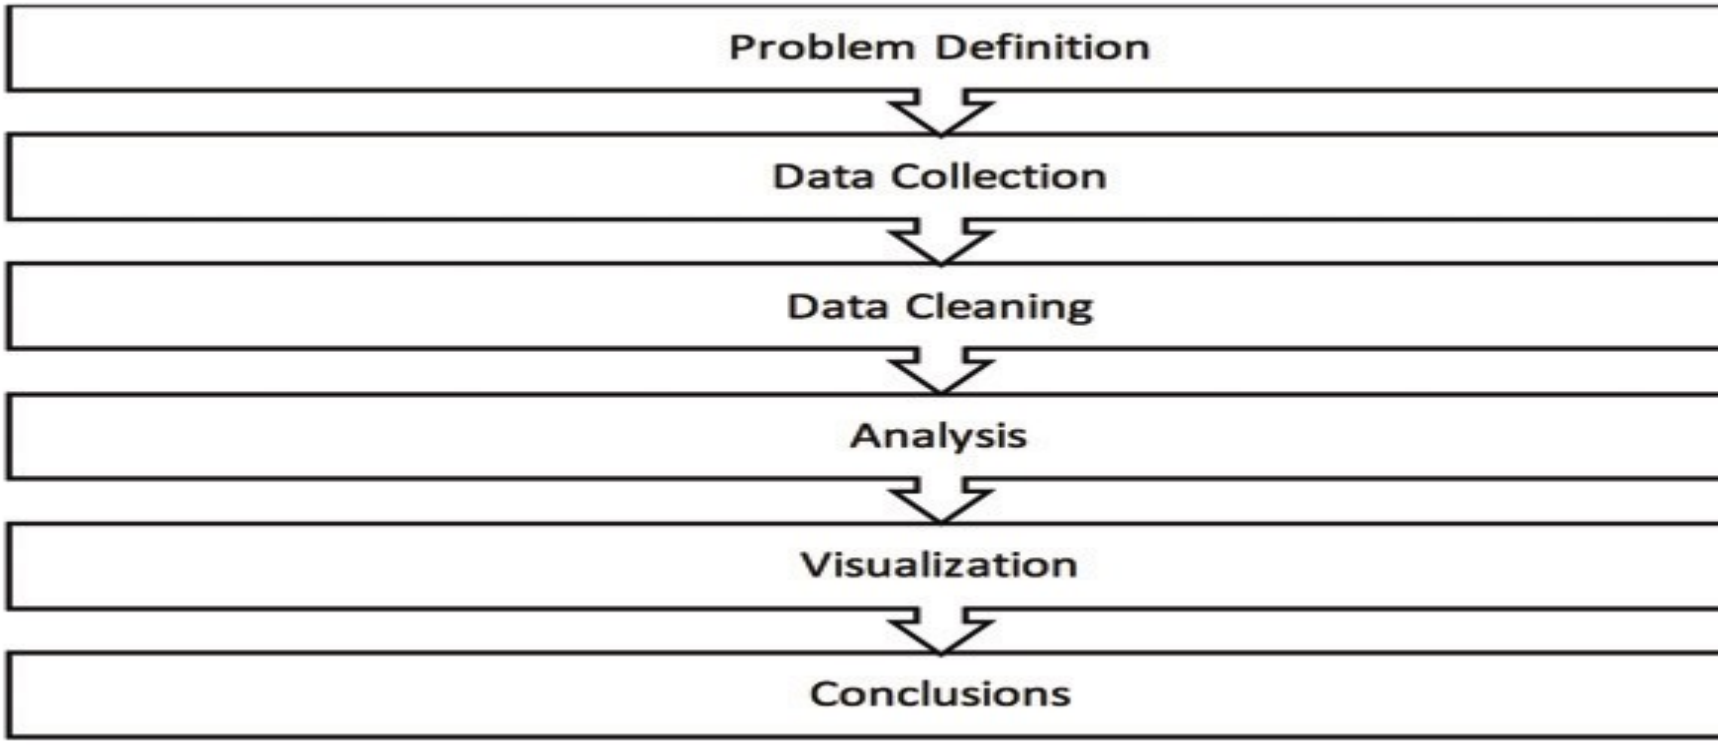
webscraping



Minería de texto



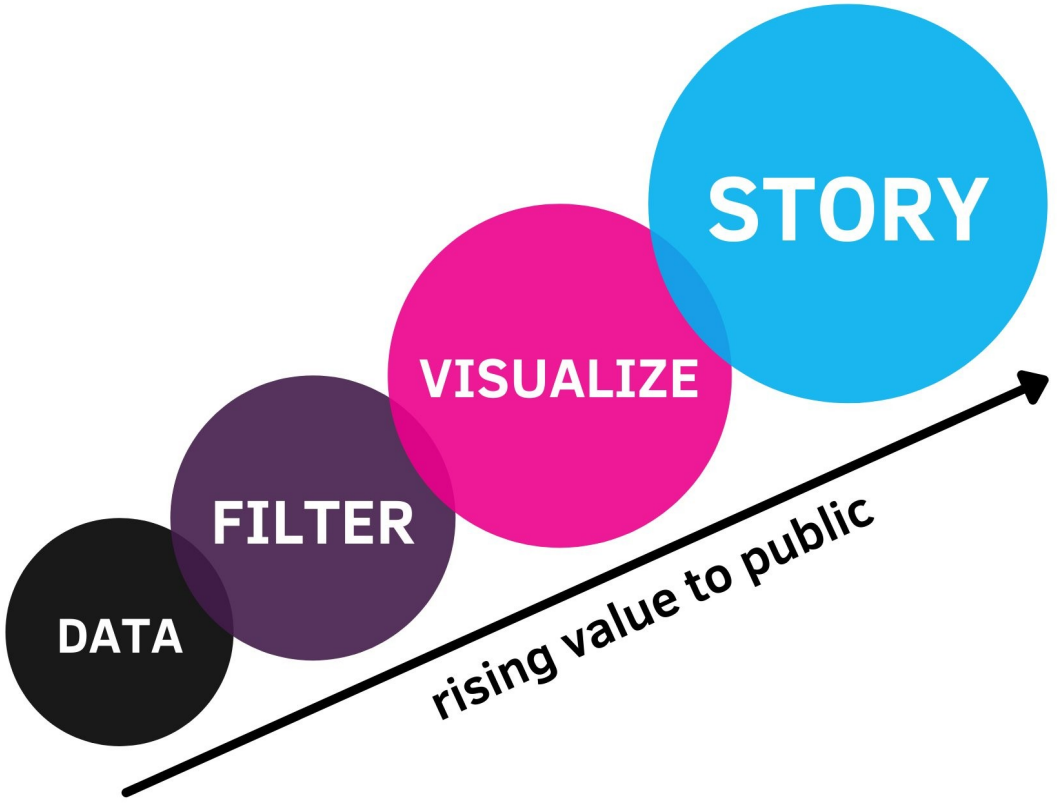
“ciencia de datos”



Algunas consideraciones.



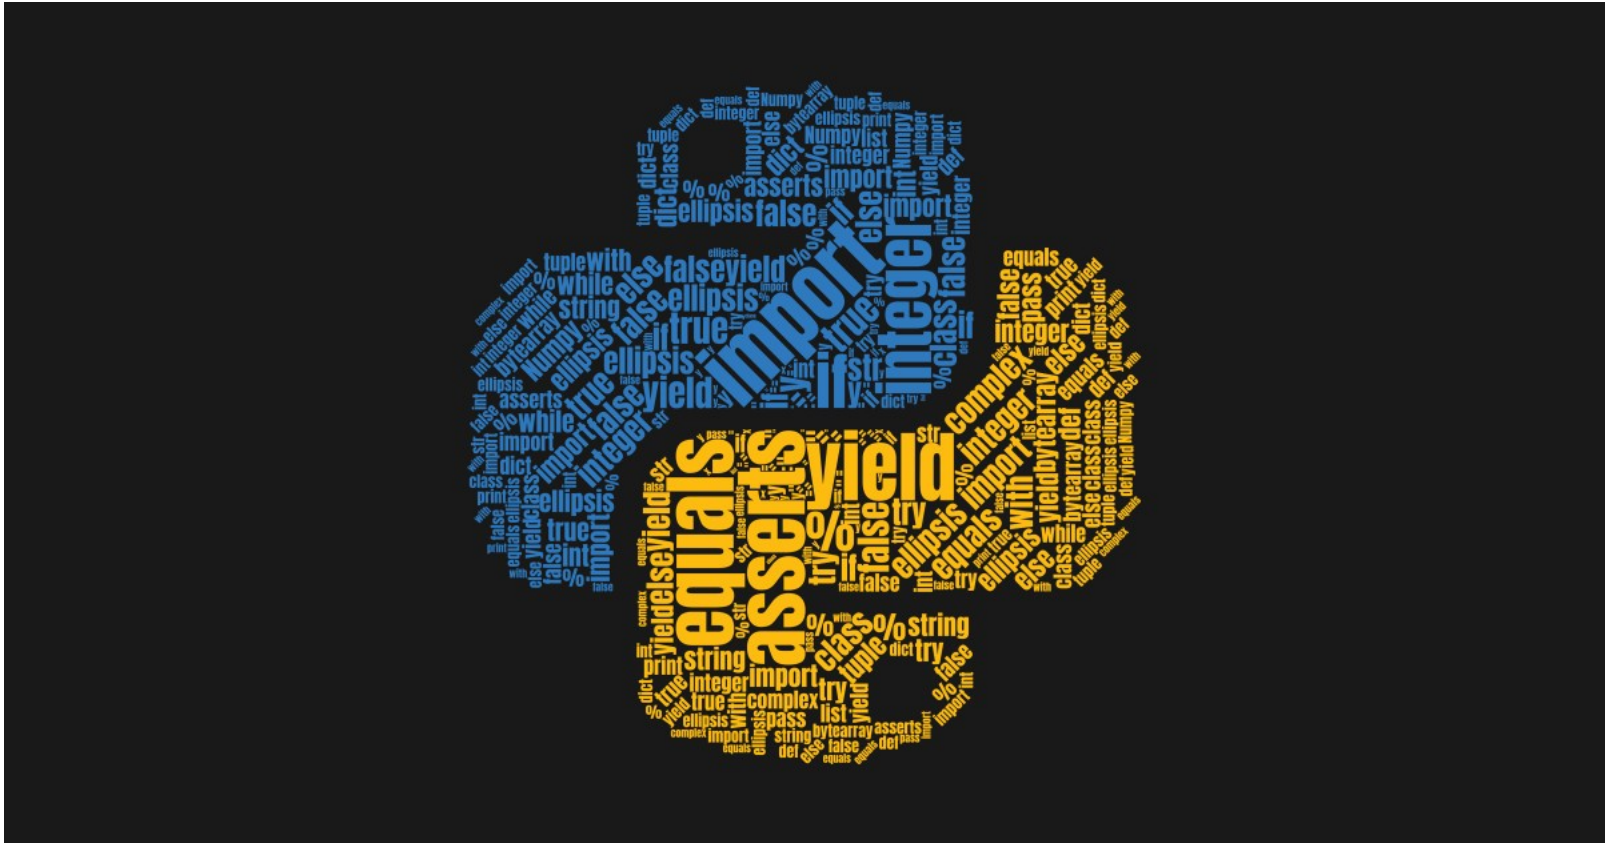
DATA-DRIVEN JOURNALISM = PROCESS



Las herramientas que vamos a necesitar



PYTHON


import
integer
yield
asserts
equals
if
else
false
ellipsis
class
true
while
with
string
try
dict
tuple
Numpy
bytearray
complex
pass
print
list
def
int
str
%
%%

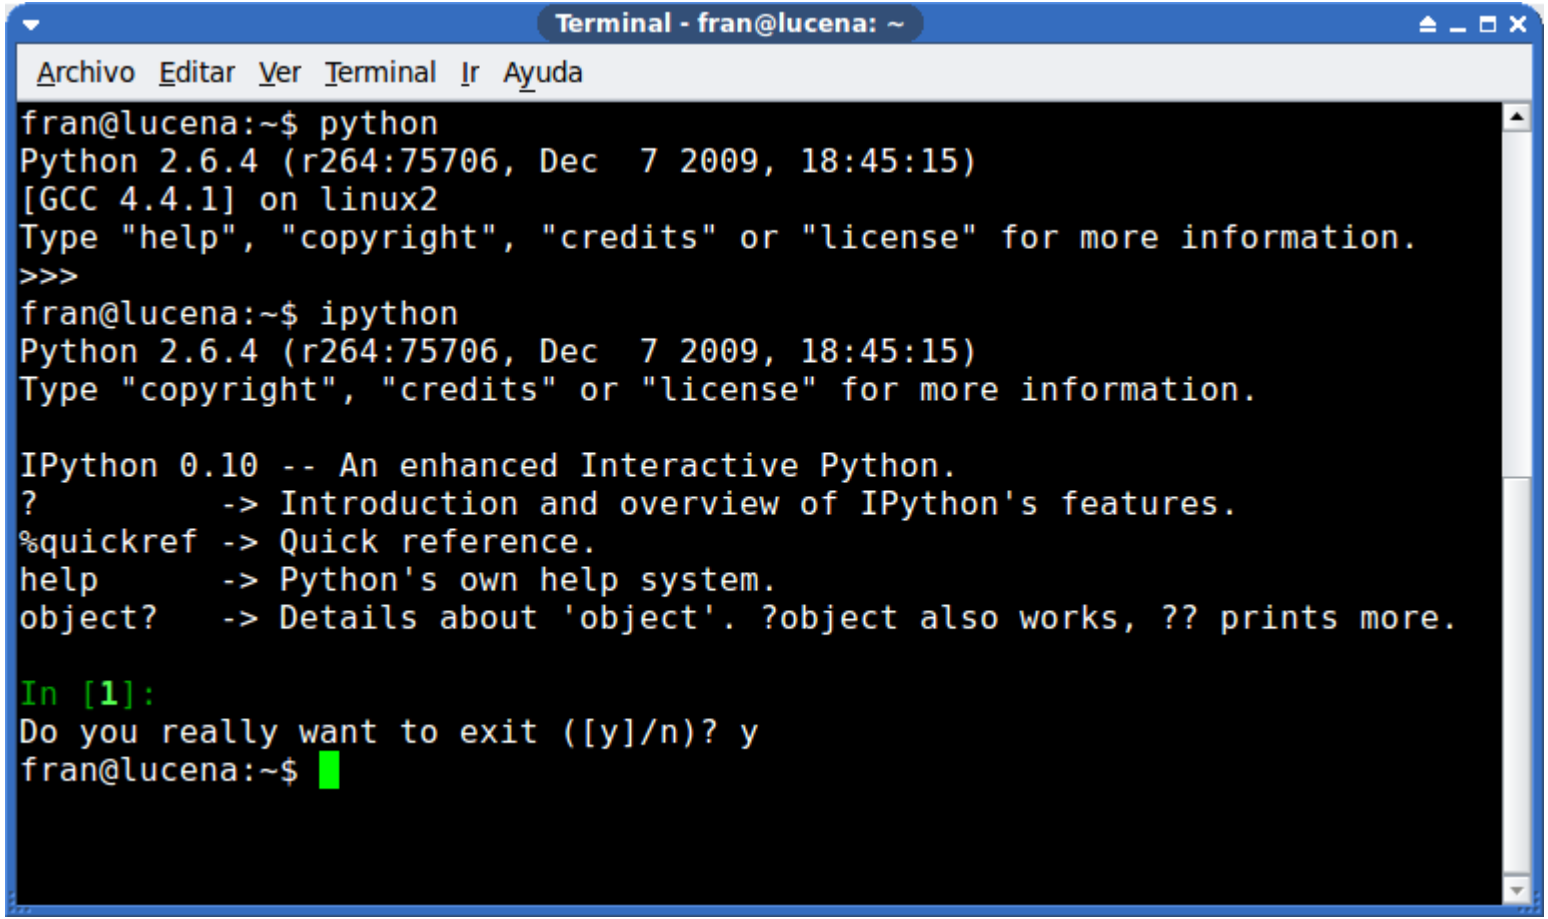
Introducción a PYTHON

- Python es un lenguaje de programación dinámica muy poderoso.
- Creado por Guido Van Rossum en 1991
- Comparado con Tcl, Perl, Ruby, Scheme o Java
- Es un lenguaje “limpio”, tiene una sintaxis legible.
- Lenguaje muy parecido al pseudocodigo.
- Recomendado para empezar a programar.

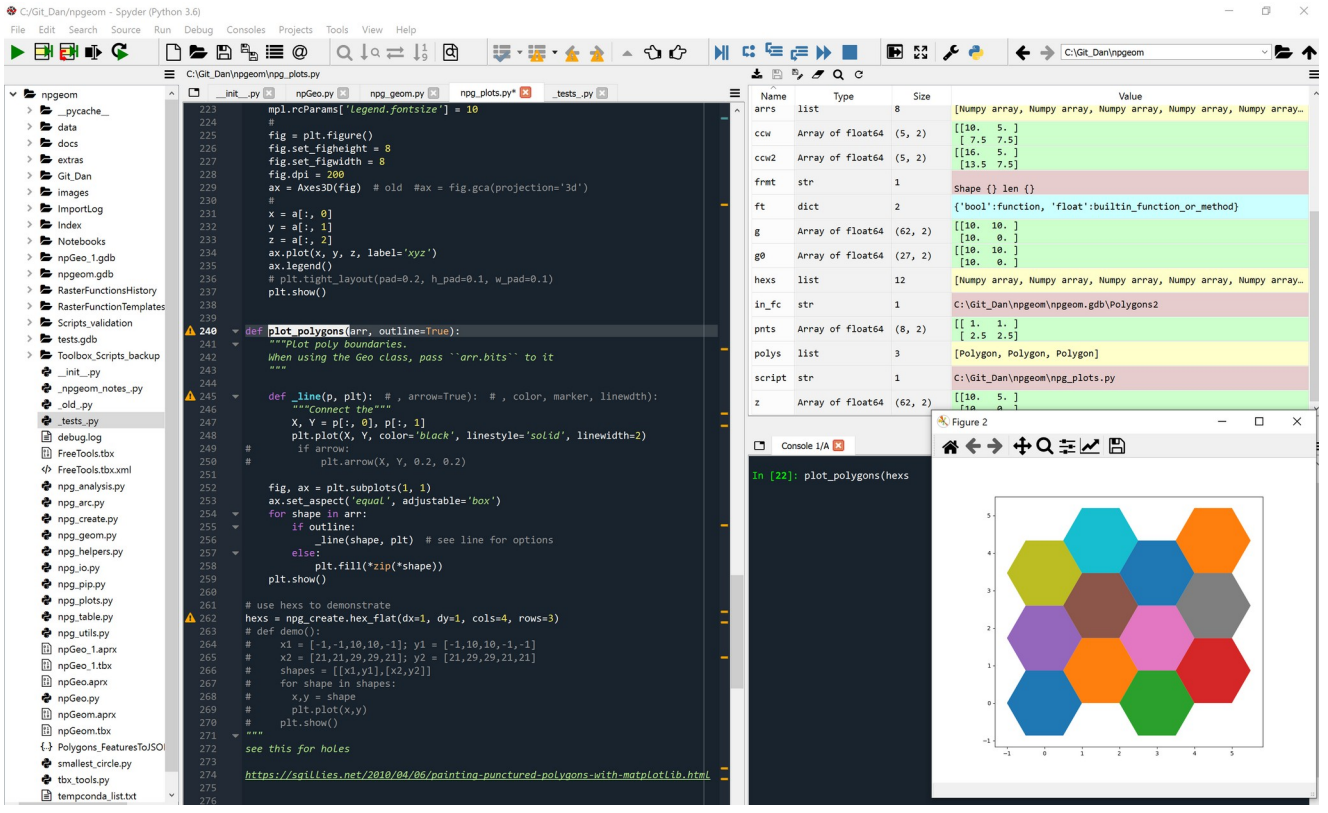
Ventajas de PYTHON

- Tiene una sintaxis fácil de aprender
- Una enorme cantidad de librerías especificas para minería de texto
- Capacidad de leer y extraer texto de páginas webs (webscraping)
- Una gran comunidad de desarrollo que da soporte y ayuda a solucionar problemas

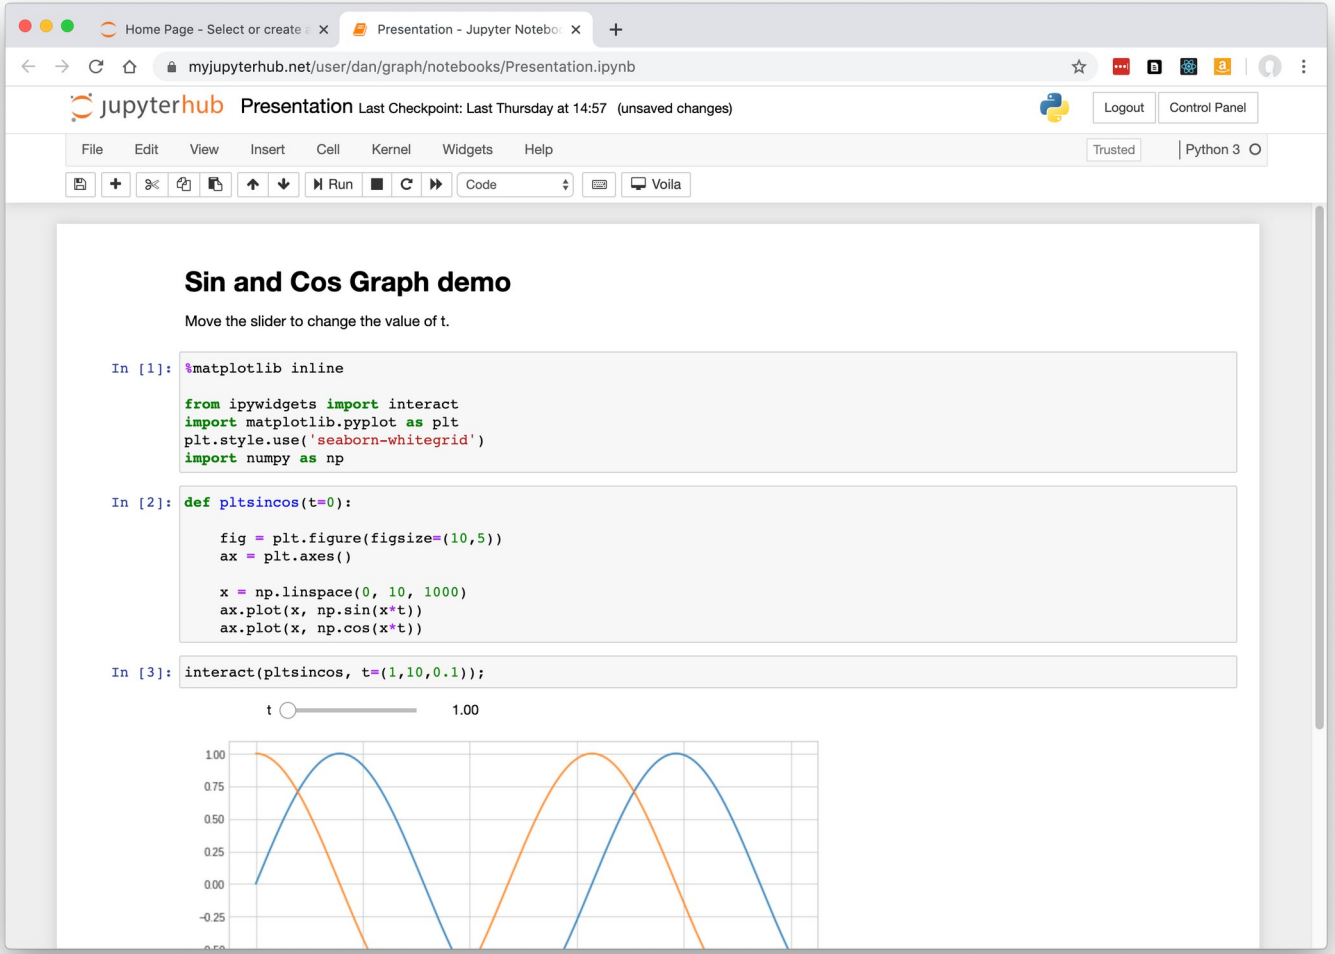
Python es un lenguaje interpretado



Entornos de desarrollo integrado (SPYDER)



Jupyter (entorno web)



Software Libre



Definición (de la FSF)

«Software libre» es el software que respeta la libertad de los usuarios y la comunidad. A grandes rasgos, significa que los usuarios tienen la libertad de ejecutar, copiar, distribuir, estudiar, modificar y mejorar el software. Es decir, el «software libre» es una cuestión de libertad, no de precio. Para entender el concepto, piense en «libre» como en «libertad de expresión», no como en «cerveza gratis». En inglés, a veces en lugar de «free software» decimos «libre software», empleando ese adjetivo francés o español, derivado de «libertad», para mostrar que no queremos decir que el software es gratuito.

Puede haber pagado dinero para obtener copias de un programa libre, o puede haber obtenido copias sin costo. Pero con independencia de cómo obtuvo sus copias, siempre tiene la libertad de copiar y modificar el software, incluso de vender copias.

¿Libre?

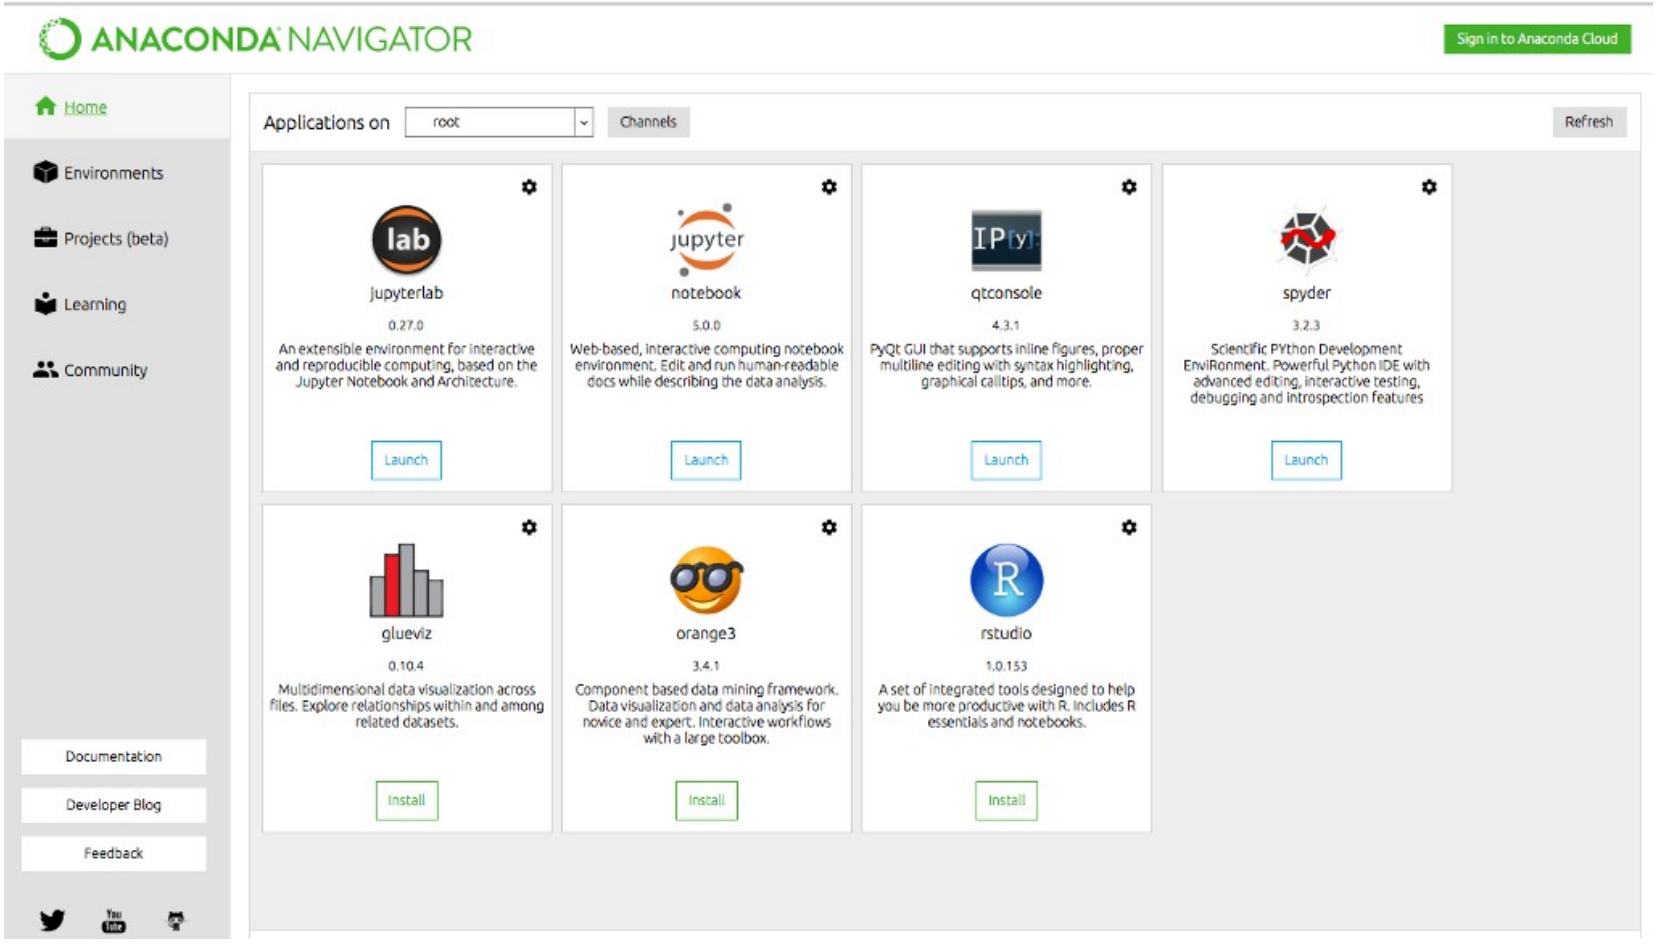
Software Libre (4 libertades)

1) La libertad de usar el programa.
2) La libertad de estudiar cómo funciona el programa y modificarlo.
3) La libertad de distribuir copias del programa.
4) La libertad de mejorar el programa y hacer públicas esas mejoras a los demás.

¿Y como usamos todo esto?



ANACONDA


ANACONDA NAVIGATOR
Sign in to Anaconda Cloud
Home
Environments
Projects (beta)
Learning
Community
Applications on
root
Channels
Refresh
jupyterlab
0.27.0
An extensible environment for interactive and reproducible computing, based on the Jupyter Notebook and Architecture.
Launch
notebook
5.0.0
Web-based, interactive computing notebook environment. Edit and run human-readable docs while describing the data analysis.
Launch
qtconsole
4.3.1
PyQt GUI that supports inline figures, proper multiline editing with syntax highlighting, graphical calltips, and more.
Launch
spyder
3.2.3
Scientific PYthon Development EnviRonment. Powerful Python IDE with advanced editing, interactive testing, debugging and introspection features
Launch
glueviz
0.10.4
Multidimensional data visualization across files. Explore relationships within and among related datasets.
Install
orange3
3.4.1
Component based data mining framework. Data visualization and data analysis for novice and expert. Interactive workflows with a large toolbox.
Install
rstudio
1.0.153
A set of integrated tools designed to help you be more productive with R. Includes R essentials and notebooks.
Install
Documentation
Developer Blog
Feedback

Anaconda

Anaconda es una distribución libre y abierta de los lenguajes Python y R, utilizada en ciencia de datos, y aprendizaje automático (machine learning). Esto incluye procesamiento de grandes volúmenes de información, análisis predictivo y cómputos científicos. Está orientado a simplificar el despliegue y administración de los paquetes de software.

Las diferentes versiones de los paquetes se administran mediante el sistema de gestión de paquetes conda, el cual lo hace bastante sencillo de instalar, correr, y actualizar software de ciencia de datos y aprendizaje automático como puede ser Scikit-team, TensorFlow y SciPy.

Librerías python útiles para científicos sociales

Recolección:

- newspaper (obtener datos de diarios o noticias históricas)
- wayback (wayback machine para buscar en webs históricas)
- selenium (automatizar extracción de datos en páginas webs)
- beatifoul soup (analizar contenido HTML de páginas webs)
- yolo (detección de objetos en distintas imágenes)
- whisper (transcripción de voz a texto)
- pypdf2 (convertir pdfs a texto)
- feedparser (datos de diarios actualizados al día)

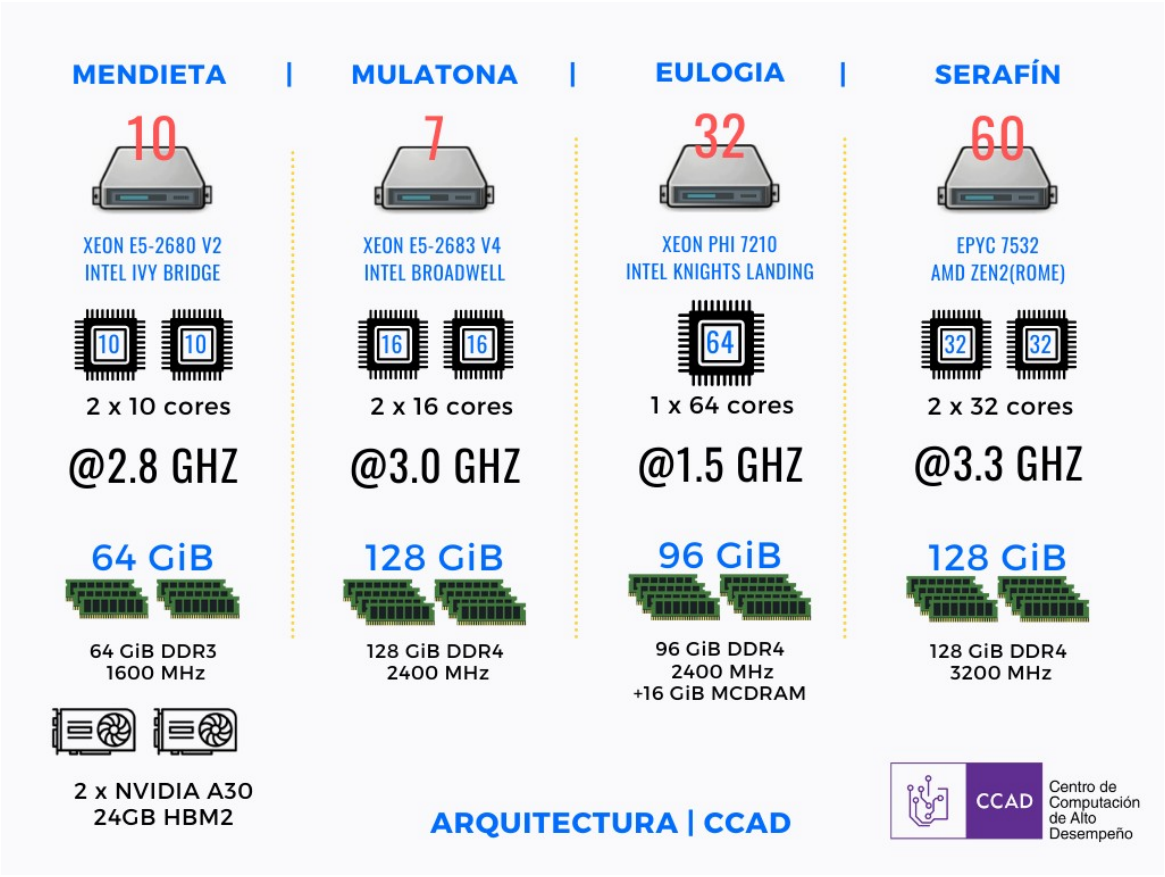
Procesamiento:

- nltk (minería de datos)
- gensim - word2vec (palabras similares suelen tener contextos similares)
- textblob (análisis de sentimientos y traducciones)
- pandas (manipulación tablas csv, excel)
- numpy (procesamiento matemático)
- spacy (minería de texto)

Visualización:

- wordcloud (nubes de palabras)
- matplotlib (gráficas)
- seaborn (gráficas)

CCAD (Centro de Cómputos de alto desempeño)



Las super computadoras de la UNC






Serafín: Uso general, reciente incorporación

Mendieta: Específico GPU, el de más trayectoria en el centro

Eulogia: Especializado en cálculos altamente paralelizables

Mulatona: Uso prioritario para el IATE y compartido (trabajos pequeños)

Comparando un proceso con python

Comparando el proceso de transcripción de 16 minutos de voz a texto usando la librería Whisper, el resultado fue:

- jupyter.ccad tiempo de procesamiento: 1029.7694115638733 (**17.1628 Minutos**)
- computadora personal (core I5, 12 Gram) tiempo de procesamiento: 2512.9579877853394 (**41.8826 Minutos**)
- google.collab (no puede trabajar la versión large por falta de memoria, probamos con la medium) tiempo de procesamiento: 2969.069447994232 (**49.4845 Minutos**)

JupyterHUB de la UNC



ventajas

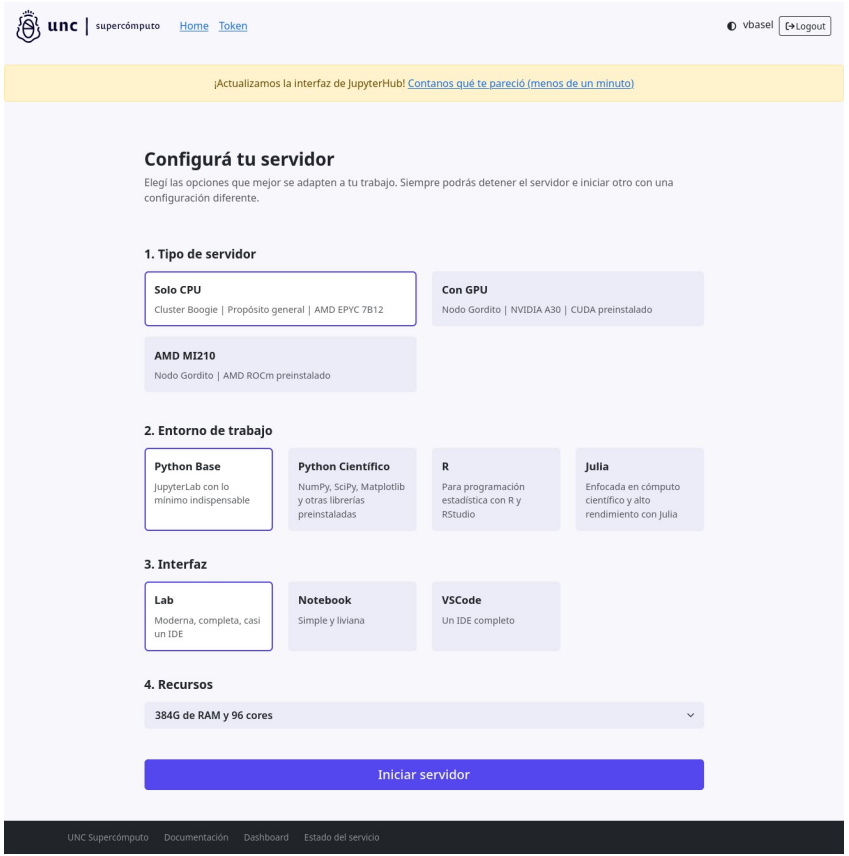
- Una interface jupyter completa, mantenida por el centro de computo de alto desempeño de la UNC
- 384 Gb de memoria RAM y 94 Cores
- Persistencia de información (no se borran las bases de datos que carguemos)
- Se puede acceder directamente con una cuenta @mi.unc.edu.ar o @unc.edu.ar

¿como entrar?

https://lab.ccad.unc.edu.ar/hub/login



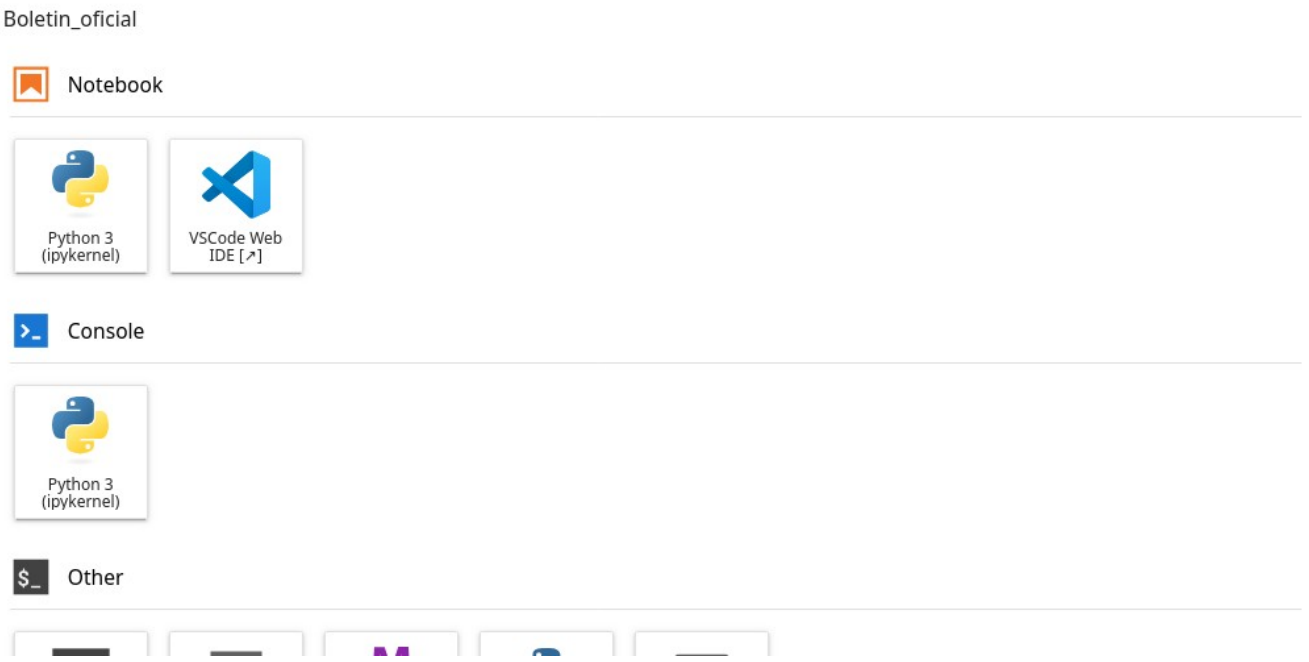
Cuando iniciamos



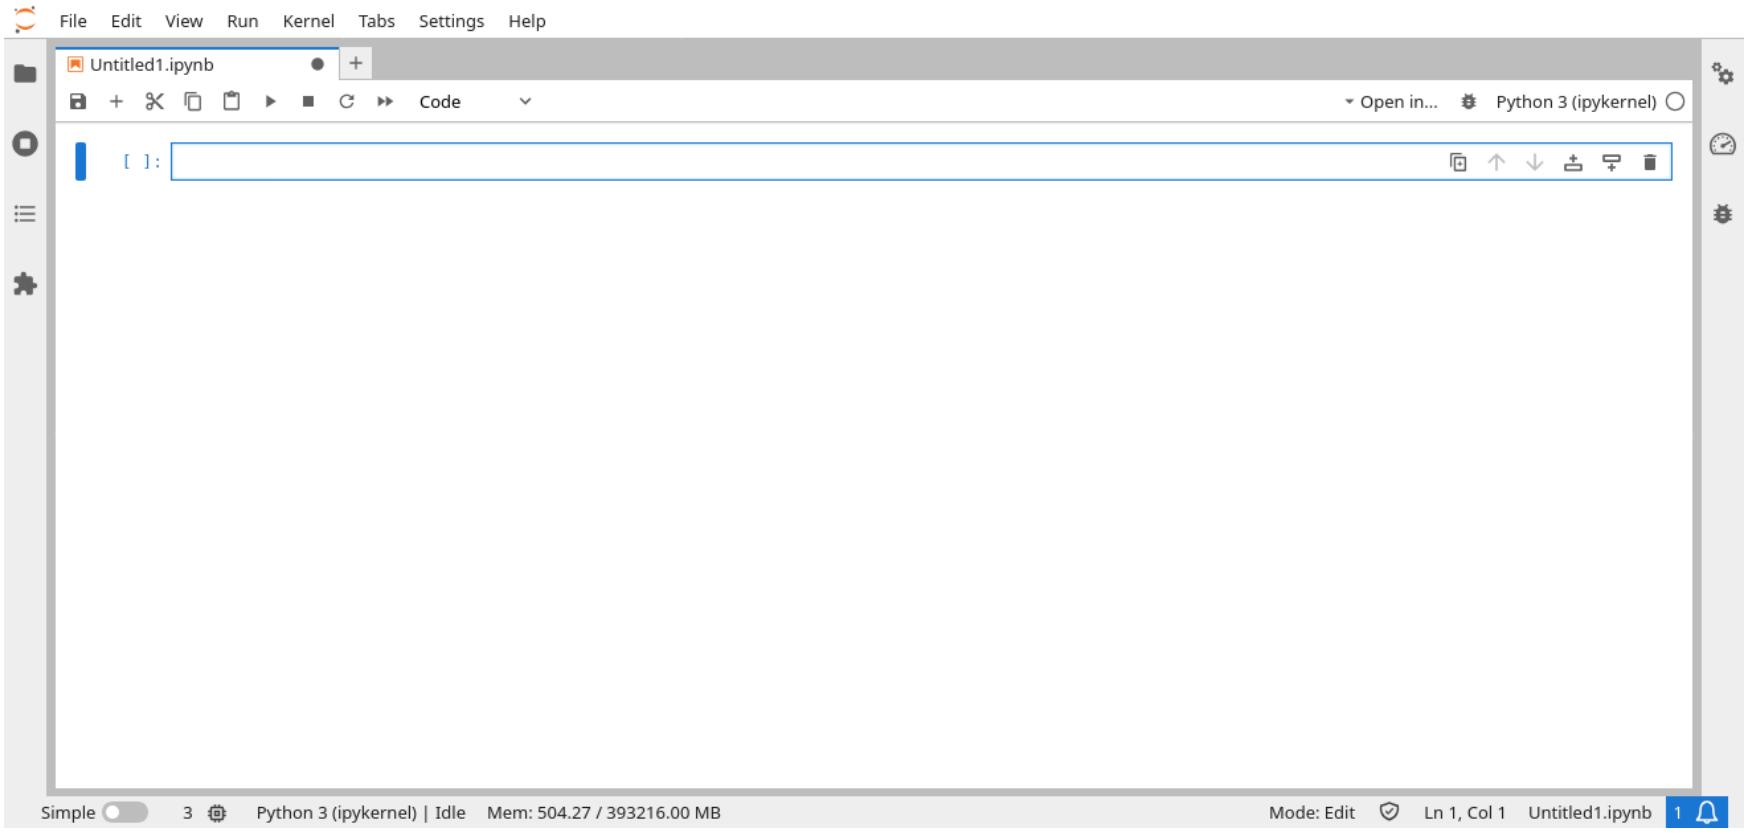
Alguna opciones



iniciando


Boletin_oficial
Notebook
Python 3 (ipykernel)
VSCode Web IDE [↗]
Console
Python 3 (ipykernel)
$_
Other

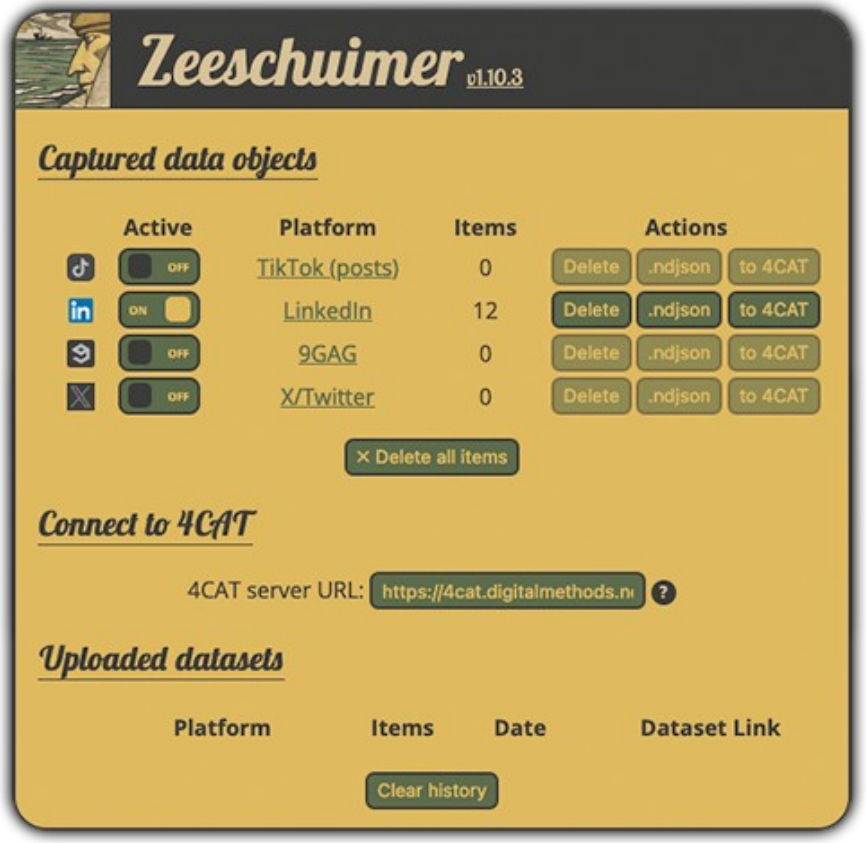
Un notebook para trabajar



Un pequeño ejemplo

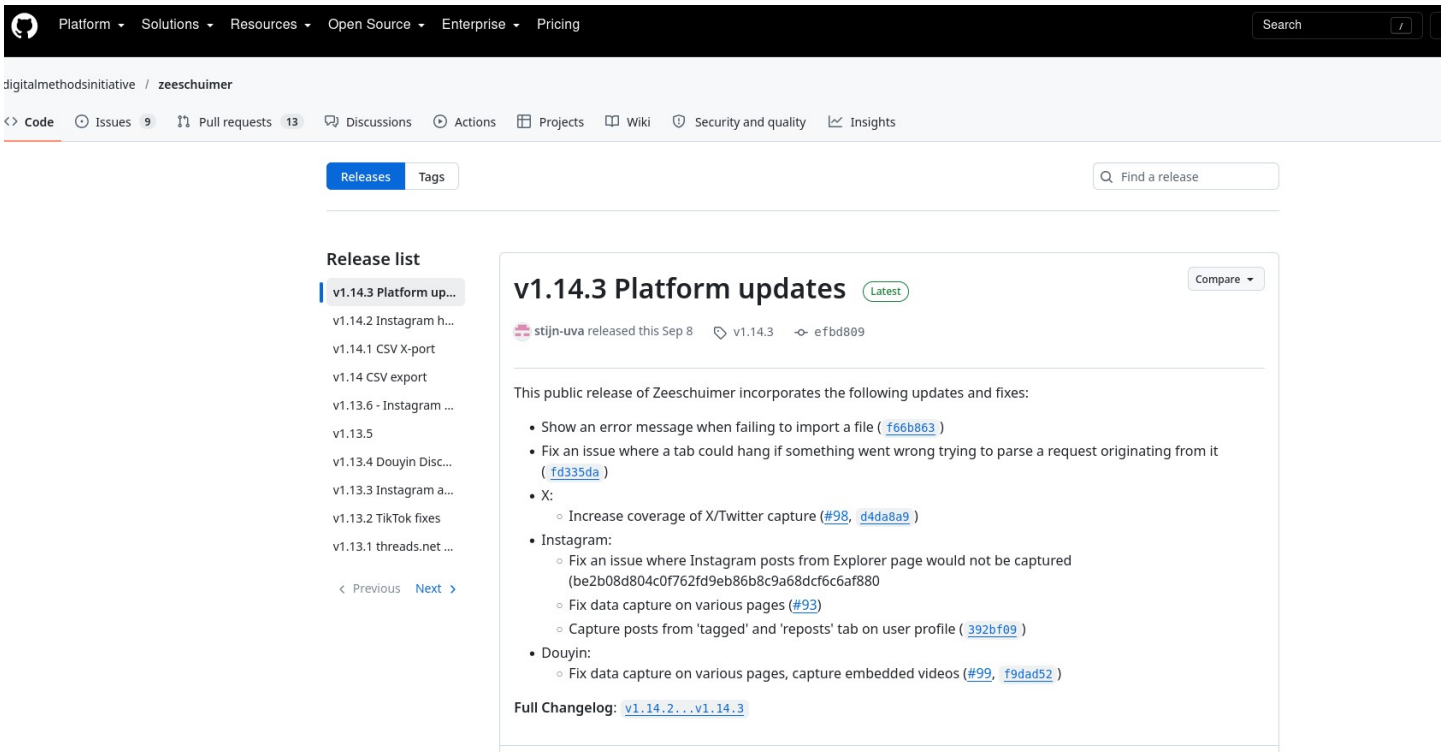
- Vamos a recolectar datos de X o tiktok
- Limpiar de palabras vacías
- Visualizar como una nube de palabras
- Todo desde jupyterhub

zeeschuimer



Como descargarlo (en firefox)

https://github.com/digitalmethodsinitiative/zeeschuimer/releases



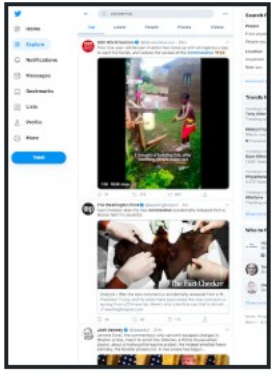
Otra alternativa
(para google Chrome)

Recolectar datos de X

The Web Data Research Assistant (aka WebDataRA)



WebDataRA is a tool has been developed by Prof Leslie Carr of the Web and Internet Science research group at the University of Southampton to support researchers using Web sourced data. Its functionality focuses on Twitter (the most commonly-researched Internet data source), but it also works for Facebook, Instagram, Tiktok, Google, Google News, Google Scholar and other database-like sites such as SSRN, Github and Quora. The ultimate aim is to make advanced network analysis and textual analysis methods accessible to social science and non-programming researchers, especially those who work in an interdisciplinary context.



>>>is transformed from a web page into a spreadsheet>>>



Installation and Support: To install the software, please go to the Chrome Web Store in your Chrome browser. The software is

Como instalarlo

https://chromewebstore.google.com/detail/web-data-research-assista/kcdbekkmigohaijilebpaeoopcgjbbdm



Una versión acortada

https://lnk.ink/U05kO



Como lo usamos



- First *close this popup* by clicking back on the main window or pressing `Esc`.
- Press `Shift-Ctrl-A` (the `Shift` key + `Control` key + the `A` key) to *activate* the data gathering process. On Twitter and Facebook this will start scrolling the page downwards to gradually obtain more of the timeline / status feed / search results.
- Press `Shift-Ctrl-H` (the `Shift` key + `Control` key + the `H` key) to *halt* the data gathering process and stop the browser scrolling. Any data gathered so far is maintained, and the process can be continued by pressing `Shift-Ctrl-A` again.
- Press `Shift-Ctrl-S` (the `Shift` key + `Control` key + the `S` key) to *save* the data gathered so far into a file.
- Press `Shift-Ctrl-Q` (the `Shift` key + `Control` key + the `Q` key) to *query* the amount of data gathered so far.
- Press `Shift-Ctrl-U` (the `Shift` key + `Control` key + the `U` key) to gather the profile data for all the Twitter *users* who were the authors of tweets, or who were mentioned in the tweets that have been gathered previously.

Limpieza de datos

- Tokenización
- Palabras vacias (stop words)
- Lemmatización
- Word2vec

vizualización

- Matplotlib
- Seaborn
- wordcloud

wordcloud


Milei
Argentina
Libertad
JMilei
historia
EconomÃ
mÃ
ser
presidente
Avanza
ExportÃ
ImportÃ
gas
nuevo
medios
grande
gente
sede
fiscal
TENDRÃ
dirÃ
PRIMEROS
PSA
dato
unido
encuentro
Grupo
Jefe
hoy
PBA
CÃ
modelo
narco
sistema
IDEAS
LLA
foto
BENEGAS
base
nLa
Si
justo
ofertas
diputados
nacionales
junto
MILLONES
EXCLUSIVA
OBLIGACIONES
PRIVATIZACIÃ
RepÃºblica
KarinaMileiOk
precios
CIERRE
Javier
PROMESAS
conseguir
Kirchner
grupito
honor
siendo
vivo
DÃ
RESULTADOS
LYNCH
apertura
privada
EMPRESAS
AYSA
NORTE
OPERADOR
SPareja_
nVLLC
cambio
dice
com
aÃ
VALORE
nÃ
estÃ
evento
mismo
INVERSIÃ
nhttps
Ministerio
Palacio
CERA
MEGAOPERATIVO
detenidos
shareÃ
mÃ
familiar
LuisCaputoAR
participaron
presos
organizada
oferentes
encuentro
proceso
culos
Santa
Rendines
Conservatorio
Brillanceamento
Marques
Toto
Ayer
dos
n29
Ministro
feature
allanamientos
participa
Exportadores
Martucci
origen
interpretados
referencia
homenaje
Patricia
Palacio
Ministerio
Kirchner
arsenal
Exportaciã³n
Argentinaã
coordinadora
youtube
Piacenza
marca
vehÃ
nEl
acto
vivo
gas
honor
siendo
conseguir
grupito
Kirchner
precios
CIERRE
Javier
PROMESAS
mismo
evento
estÃ
INVERSIÃ
nhttps
cambio
presente
presidente
dice
EMPRESAS
AYSA
LYNCH
apertura
privada
mÃ
NORTE
OPERADOR
SPareja_
Avanza
nuevo
nVLLC
foto
BENEGAS
base
IDEAS
LLA
sistema
nacionales
junto
MILLONES
fiscal
gente
sede
grande
unido
encuentro
Grupo
Jefe
hoy
PBA
CÃ
modelo
narco
PRIVATIZACIÃ
RepÃºblica
KarinaMileiOk
EXCLUSIVA
OBLIGACIONES
nLa
TENDRÃ
dirÃ
PRIMEROS
PSA
dato
Si
justo
ofertas
diputados
medios
ser
JMilei
Libertad
Argentina
Milei

Un ejemplo en google colab

https://lnk.ink/AkpLh



FIN!

Contacto: valentinbasel@unc.edu.ar